

1. 주제 및 데이터

- 2025 전력 사용량 예측 AI 경진대회

- 데이터

1) train.csv: 85일 분량의 데이터 - 100개 건물들의 2024년 6월 1일부터 2024년 8월 24일 까지의 데이터, 일시별 기온, 강수량, 풍속, 습도, 일조, 일사 정보, 전력사용량 포함

2) building_info.csv: 100개 건물 정보 - 건물 번호, 건물 유형, 연면적, 냉방 면적, 태양광 용량, ESS 저장 용량, PCS 용량

3) test.csv: 100개 건물들의 2024년 8월 25일부터 2024년 8월 31일까지의 데이터 - 일시별 기온, 강수량, 풍속, 습도의 예보 정보

2. 코드 리뷰

1) 데이터 전처리

(1) 전력소비량이 급격하게 낮아지거나 높아지는 구간 -> 이상치 구간을 단일 값과 연속 값으로 구분하여, 단일 값은 보간으로 대체하고 연속 구간은 제거함

(2) 기본 시간 단위(월, 일, 시, 주차, 요일)를 추출하여 주기적 패턴을 반영함, 사인 코사인 변환을 통해 하루 24시간의 사이클 피처를 모델에 효과적으로 전달함, 여름 기간의 계절성 반영을 위해 summer_sin, summer_cos 추가함

(3) 주말과 법정 공휴일은 전력 소비량이 낮은 패턴을 보이므로 해당 일자를 holiday 변수로 추가하여 학습에 반영함

(4) 일부 건물들에서 공휴일이 아님에도 전력 사용량이 현저히 낮은 일자 존재함 -> 공휴일이 목요일 다음날인 금요일을 임시 휴일로 처리하여 연휴로 봄, 매월 2,4번째 월요일을 휴일로 지정함



(5) 기온, 습도에 대해 1일, 4일, 7일 이동평균과 시간차 기반 변화량을 생성하여 기상 조건의 추세와 변동성을 반영함

(6) 일 단위 평균, 최대, 최소값 및 일교차, 습도차를 추가함

(7) 실제 체감 환경과 에너지 수요를 정교하게 반영한 불쾌지수(THI), 냉방도시(CDH), 체감 온도(WCT) 생성

(8) 요일, 시간대별 평균 전력소비량, 휴일 여부별 평균 전력소비량, 휴일 여부별 표준편차, 시간대별 평균 전력소비량, 시간대별 표준편차 등 통계 기반 파생 변수 생성

(9) 전력 사용량 분포가 한쪽으로 치우쳐 있으므로 로그 변환으로 분포를 정규화하여 모델 학습 안정성과 예측 성능 개선



2) 모델링

(1) XGBoost 모델

(2) Loss Function: Weighted MSE를 사용하여 전력소비량의 과소예측을 더 크게 패널티 주도록 설계

(3) 5-fold 교차검정 앙상블과 seed 앙상블을 결합하여 예측 안정성과 성능을 향상

- 다양한 그룹화 전략을 이용

a. 건물별 그룹: 개별 건물 특성을 최대한 반영

b. 건물유형별 그룹: 건물 유형별 특성을 최대한 반영

c. 전력사용량 상관관계별 그룹: 일부 건물유형은 패턴이 유사하지 않아서 상관관계 기반 그룹화로 보다 일관된 패턴 학습

d. 건물별로 구분하는 변수 추가

3. 차별점 및 배울점

다양한 그룹화 전략을 활용하여 모델 예측 성능을 향상시킨 점이 인상깊었다. 특히 건물별 특성을 최대한 파악하기 위해 그룹화 전략을 사용할 때 건물별 그룹도 나누고 건물유형별 그룹도 나누고, 또 건물별 변수도 추가하고, 전력사용량 상관관계별 그룹도 나눠본 점에서 그룹화 시 다양한 기준을 가지고 분류를 진행해보아야겠다고 느꼈다.