

1. 주제 및 데이터

난임 환자 대상 임신 성공 여부 예측 AI

train.csv: ID(샘플별 고유 ID), 난임 환자 시술 데이터 67개의 컬럼, 임신 성공 여부(1: 성공, 0: 실패)

test.csv: D(샘플별 고유 ID), 난임 환자 시술 데이터 67개의 컬럼

2. 코드 리뷰

1) 데이터 분석

(1) 불균형한 학습 데이터 분포: 임신 성공 여부에 따른 학습 데이터 수가 약 3:1로 매우 불균형한 수치를 가짐

(2) 결측치가 많은 피처 확인: 특정 피처들의 경우 약 95% 이상의 데이터가 결측치로 존재함 -> 결측치 대체 및 feature drop과 같은 전처리 방향성 고려

(3) 연결 및 포함 관계를 이루는 feature 파악: 시술 유형에 따라 특정 피처의 결측 비율이 결정되고, 총 출산 횟수와 총 임신 횟수, 미세주입 배아 이식 수와 이식된 배아 수는 포함 관계임

(4) 도메인 지식을 통한 분석: 시술 당시 나이의 중요성, 배아 배양일의 중요성, 환자별 시술 여정에 대한 이해의 중요성 등 시술 과정의 차이를 모델 학습에 활용하기 위한 파생변수의 중요성을 파악하고 새로운 전처리 아이디어를 얻음

2) MICE(Multivariate Imputation by Chained Equations)를 통한 결측치 처리: 변수 간의 dependency를 이용해 결측값을 반복적으로 채움

3) 컬럼 간 관계도를 통한 파생변수 생성

- $df['IVF \text{ 시술 비율}] = np.where((df['IVF \text{ 시술 횟수}] + df['DI \text{ 시술 횟수}]) \neq 0, -1, df['IVF \text{ 시술 횟수}] / (df['IVF \text{ 시술 횟수}] + df['DI \text{ 시술 횟수}]))$: 환자 별로 IVF, DI 시술 횟수가 다르기 때문에 동등한 기준에서 IVF 시술을 얼마나 더 많이 했는지에 대한 정보를 주고자 파생변수 생성

- $df['\text{이식된 배아 수 대비 미세주입 배아 수}] = np.where(df['\text{이식된 배아 수}] \neq 0, -1, df['\text{미세주입 배아 이식 수}] / df['\text{이식된 배아 수}])$: 이식된 배아 수 대비 미세주입 배아 이식을 한 비율을 파생 변수로 만들어서 미세주입 효과를 보여주고자 함

4) 모델 선택 및 최적화

(1) CatBoost: 범주형 데이터 처리 시 오버피팅을 방지하며, 피처 간의 결합 등을 통해 효과적으로 학습함

(2) Optuna 하이퍼파라미터 튜닝: logloss를 최소화하는 방향으로 최적화 진행

(3) OOF (Out-Of-Fold) Prediction: K-Fold 검증에서 나온 예측값을 모아 Stacking이나 앙상블에 활용함, 단순 CV보다 더 좋은 성능을 발휘하며 과적합을 방지함

(4) Stratified K-Fold 교차 검증: 학습 데이터의 class 분포를 fold별로 균일하게 분배하여 학습을 진행함

5) 평가: confusion matrix와 Accuracy, Precision, Recall, F1-score, AUC-ROC를 분석한 결과 불균형적인 학습 분포로 인해 임신 성공 여부보다 실패 여부를 월등히 더 잘 예측한다는 것을 확인함

6) 개선점

1) CatBoost parameter class weight 조절 혹은 SMOTE 기법을 활용하여 불균형한 학습 데이터를 조정함

2) 도메인 지식을 활용하여 Mice 모델 이전 추가적인 전처리 과정을 수행함

3) Catboost 모델뿐만 아니라 다른 ML Model을 이용하여 앙상블 모델을 구축함

3. 차별점 및 배울점

파생변수 생성에 포커스를 맞춘 점이 인상깊었다. 그동안의 미니 프로젝트에서는 앙상블에서 다양한 모델을 어떻게 적절하게 섞어서 더 나은 모델을 만들지 고민하는 시간이 많았는데, 앞으로는 변수들간의 관계를 파악하고, 이를 잘 반영한 파생변수를 만드는 것에도 신경을 써야겠다.